

Entrega Final - Proyecto MAIA

SciText-ES: analisis de documentos cientificos en espanol
Tema 1 - 2026 | Universidad de los Andes | Grupo FLAG-TICsW

Proyecto: SciText-ES

Integrantes: Alvaro Andres Ruiz Florez, Jose David Yepes Tumay, Andres Julian Gonzalez Barrera

Resumen ejecutivo

SciText-ES es una solucion para el analisis automatico de documentos cientificos en espanol. **El proyecto cubre dos tareas:** (1) segmentacion y clasificacion retorica por parrafo y (2) deteccion de contribuciones cientificas. La entrega incluye aplicacion web funcional, documentacion de instalacion y uso, notebooks centralizados, datos gestionados con DVC y modelos organizados por tarea.

Enlaces de entrega

Repositorio GitHub: <https://github.com/jdyapest/proyecto-flag-2026-jose-julian>

Aplicacion desplegada: <http://100.52.250.51:5000/>

Video de demostracion:

<https://drive.google.com/file/d/1TwTTJRdqqw3XYvbOdjid60hSO5KLIH5I/view?usp=sharing>

Respaldo de runs/modelos en Drive (1):

<https://drive.google.com/drive/folders/1udVwPnN5Ep80qQ7ck2DjayhqiktzHWat?usp=sharing>

Respaldo de runs/modelos en Drive (2): <https://drive.google.com/drive/folders/1BWNBJQ4-ktDpig4SMOlPvP0NffhKmTg?usp=sharing>

Cumplimiento de la entrega

Elemento solicitado	Estado	Evidencia / observacion
Repositorio en GitHub	Listo	Repositorio publico con README, manuales y estructura de entrega.
Aplicacion funcional desplegada	Listo	Disponible en la URL publica oficial del proyecto.
README del proyecto	Listo	Incluye descripcion, uso, enlaces, dependencias, entorno, despliegue y rutas de modelos.
Carpeta Notebooks/	Listo	Los cuadernos de entrenamiento y pruebas

Elemento solicitado	Estado	Evidencia / observacion
		están centralizados en notebooks/.
Carpeta Modelos/	Listo	La carpeta está trackeada con DVC mediante Modelos.dvc y organizada por tarea.
Carpeta Datos/	Listo	Datos/ documenta la estructura real en data_lake/ y el uso de DVC.
Integrantes y nombre del proyecto	Listo	Se incluyen en este documento y en README.md.

Estructura relevante del repositorio

- README.md: documento principal de referencia para instalación, uso y despliegue.
- notebooks/: cuadernos de análisis, entrenamiento y pruebas.
- Modelos.dvc + Modelos/: puntero DVC y artefactos de modelos organizados por task1 y task2.
- Datos/ y data_lake/: carpeta de entrega y estructura operativa real de datasets, manifests y scripts.
- docs/: manual de instalación, manual de usuario y este documento final de entrega.
- app/: backend Flask, frontend estático y proxy LLM para el modo llm.

Instalación resumida

1. Clonar el repositorio desde GitHub y crear un entorno virtual.
2. Instalar dependencias con `pip install -r app/backend/requirements.txt` y `pip install -r requirements.txt`.
3. Recuperar artefactos grandes con `dvc pull data_lake/clean_parquet.dvc data_lake/datasets.dvc Modelos.dvc`.
4. Configurar .env con las variables de servicios externos y los modelos encoder por tarea.
5. Levantar el backend con `python app/backend/main.py` y abrir la aplicación en `http://localhost:5000`.

Nota operativa: cuando los modelos encoder se consumen por rutas `s3://...`, la primera corrida normal puede tardar más por la descarga inicial. En Docker, esa descarga puede impactar el build time o el primer arranque según como se materialice el cache.

Modelos y mecanismos de acceso

- Flujo recomendado: una variable por tarea usando `TASK1_ENCODER_MLFLOW_MODEL_URI` y `TASK2_ENCODER_MLFLOW_MODEL_URI` apuntando a `s3://...`
- Alternativa reproducible: descargar Modelos/ con DVC y usar `TASK1_ENCODER_MODEL_PATH` y `TASK2_ENCODER_MODEL_PATH`.

- Compatibilidad: las URIs runs:/... y models:/... siguen siendo posibles si se levanta MLflow localmente.
- Fallback manual: si DVC o S3 no estan disponibles, los respaldos de Drive permiten reconstruir la carpeta Modelos/ para la entrega o validacion local.

Uso funcional de la aplicacion

- La URL oficial desplegada es <http://100.52.250.51:5000/>.
- El tablero permite ejecutar Tarea 1, Tarea 2 o ambas sobre textos cientificos en espanol.
- El backend expone el endpoint POST /api/analyze para analisis y GET /api/compare/{analysis_id} para comparacion de modelos.
- Para el uso normal del tablero no es necesario especificar encoder_variant; el despliegue ya resuelve el encoder configurado.

Observaciones finales

- La documentacion publica del repositorio fue alineada para priorizar S3 directo o DVC + rutas locales como flujos principales de modelos.
- Los manuales de instalacion y usuario ya reflejan el estado actual del despliegue, incluyendo la URL publica, las variables recomendadas y los respaldos de Drive.
- El objetivo de esta entrega es que el evaluador pueda acceder al repositorio, revisar la estructura exigida y ejecutar o validar la aplicacion con la menor friccion posible.